

SLI / SLO Design for FastAPI Service

1. Service Overview

본 문서는 FastAPI 기반 HTTP API 서비스에 대해

SRE 관점에서 SLI(Service Level Indicator)와 SLO(Service Level Objective)를 설계한 결과를 정리한 문서이다.

본 서비스는 신뢰성 실험을 목적으로 구성된 API 서비스로,

정상 응답, 지연 응답, 서버 오류(HTTP 5xx)를 의도적으로 재현할 수 있다.

SLI/SLO 설계의 목적은 다음과 같다.

- 사용자 경험을 정량적으로 측정할 수 있는 지표 정의
- 서비스 신뢰성 목표를 명확히 설정
- Alerting 및 Incident Response의 판단 기준 제공

2. Service Scope & User Journey

2.1 Service Definition

- Service name: fastapi-app
- Service type: HTTP API service
- Users: 내부 사용자 / 데모 사용자

본 SLI/SLO는 서버 측 서비스 품질을 기준으로 정의되며, 클라이언트 네트워크 오류나 사용자 입력 오류는 평가 대상에서 제외한다.

2.2 Critical User Journeys

서비스 신뢰성은 다음 핵심 사용자 흐름을 기준으로 평가한다.

- UJ-1: GET /health 요청이 200 OK를 반환
- UJ-2: 주요 API 엔드포인트가 허용 가능한 지연시간 내에 정상 응답

3. SLI Selection Rationale

SLI는 다음 기준을 만족하는 지표로 선택하였다.

- **User-centric**
실제 사용자 경험을 반영할 수 있는 지표
- **Measurable**
Prometheus를 통해 정량적으로 수집 및 계산 가능
- **Actionable**
운영 의사결정(대응, 개선)에 직접 활용 가능

이 기준에 따라 다음 세 가지 SLI를 선택하였다.

- Availability (Success Rate)
- Latency (p95)
- Error Rate (HTTP 5xx)

4. SLI Definitions

4.1 SLI-1: Success Rate (Availability)

정의

전체 요청 중 성공적으로 처리된 요청의 비율을 의미한다.

- Good events: HTTP 2xx, 3xx
- Bad events: HTTP 5xx
- Excluded: HTTP 4xx (클라이언트 오류로 간주)

의미

Success Rate는 서비스가 정상적으로 요청을 처리할 수 있는지를 나타내는 가장 직접적인 가용성 지표이다.

4.2 SLI-2: Request Latency (p95)

정의

HTTP 요청 지연시간의 95퍼센타일 값으로,
Histogram 메트릭을 기반으로 계산한다.

의미

- 평균 지연시간이 숨길 수 있는 tail latency를 반영
- 사용자 체감 성능을 평가하는 데 적합

4.3 SLI-3: Error Rate (HTTP 5xx)

정의

전체 요청 중 서버 측 오류(HTTP 5xx)가 차지하는 비율이다.

의미

- 서버 처리 실패를 직접적으로 반영
- Availability SLI를 보완하는 실패 지표

5. SLO Definitions

각 SLI에 대해 정량적인 목표(SLO)를 다음과 같이 정의한다.

5.1 SLO-1: Availability

- **SLI:** Success Rate
- **Target:** $\geq 99.9\%$
- **Window:** Rolling 30 days
- **Scope:** 전체 서비스 엔드포인트

5.2 SLO-2: Latency

- **SLI:** Request Latency (p95)
- **Target:** $\leq 300\text{ms}$
- **Window:** Rolling 30 days
- **Scope:** 주요 사용자 대상 엔드포인트

5.3 SLO-3: Error Rate

- **SLI:** Error Rate (HTTP 5xx)
- **Target:** $\leq 0.1\%$
- **Window:** Rolling 30 days
- **Scope:** 전체 서비스 엔드포인트

6. SLO Summary

SLO	SLI	Target	Wiindow
SLO-1	Success Rate	$\geq 99.9\%$	30 days
SLO-2	Latency (p95)	$\leq 300\text{ms}$	30 days
SLO-3	Error Rate	$\leq 0.1\%$	30 days

7. Error Budget

Error Budget은 정의된 SLO를 기준으로 허용 가능한 실패 범위를 의미한다.

본 프로젝트에서는 다음과 같이 계산한다.

Error Budget = 1 - SLO Target

Availability SLO 기준으로,

30일 동안 전체 요청 중 최대 0.1%의 실패는

SLO 위반으로 간주되지 않는다.

8. Operational Interpretation

Error Budget은 운영 우선순위를 결정하는 기준으로 활용된다.

- Error Budget 소모가 빠를 경우
→ 안정성 개선 및 장애 원인 분석을 우선
- Error Budget이 안정적으로 유지될 경우
→ 기능 개발 및 배포를 정상적으로 진행 가능

본 SLI/SLO 설계는 이후

Alerting, Incident Response, RCA의 판단 기준으로 활용된다.

9. Conclusion

본 문서는 FastAPI 서비스에 대해

사용자 경험 중심의 SLI와 현실적인 SLO를 설계한 결과를 정리하였다.

이를 통해 서비스 신뢰성을

정량적으로 측정하고, 운영 의사결정에 활용할 수 있는 기반을 마련하였다.